

法律声明

■ 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，北风网和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

■ 课程详情请咨询

◆ 微信公众号：北风教育

◆ 官方网址：<http://www.ibeifeng.com/>



人工智能之机器学习

隐马尔可夫模型

主讲人：Gerry

上海育创网络科技有限公司



课程要求

■ 课上课下 “九字” 真言

- ◆ 认真听，善摘录，勤思考
- ◆ **多温故，乐实践**，再发散

■ 四不原则

- ◆ **不懒散惰性，不迟到早退**
- ◆ **不请假旷课，不拖延作业**

■ 一点注意事项

- ◆ 违反 “四不原则”，不包就业和推荐就业

严格是大爱



寄语



做别人不愿做的事，
做别人不敢做的事，
做别人做不到的事。

课程内容

- 隐马尔可夫模型
- Viterbi算法
- 特征提取

马尔可夫性质


- 设 $\{X(t), t \in T\}$ 是一个随机过程， E 为其状态空间，若对于任意的 $t_1 < t_2 < \dots < t_n < t$ ，任意的 $x_1, x_2, \dots, x_n, x \in E$ ，随机变量 $X(t)$ 在已知变量 $X(t_1)=x_1, \dots, X(t_n)=x_n$ 之下的条件分布函数只与 $X(t_n)=x_n$ 有关，而与 $X(t_1)=x_1, \dots, X(t_{n-1})=x_{n-1}$ 无关，即条件分布函数满足下列等式，此性质称为马尔可夫性；如果随机过程满足马尔可夫性，则该过程称为马尔可夫过程。

$$p(X(t) \leq x | X(t_1) = x_1, \dots, X(t_n) = x_n) = p(X(t) \leq x | X(t_n) = x_n)$$

$$p(X_{n+1} = x | X_1 = x_1, \dots, X_n = x_n) = p(X_{n+1} = x | X_n = x_n)$$

马尔可夫链


- 马尔可夫链是指具有马尔可夫性质的随机过程。在过程中，在给定当前信息的情况下，过去的信息状态对于预测将来状态是无关的。
- 在马尔可夫链的每一步，系统根据概率分布，可以从一个状态变成另外一个状态，也可以保持当前状态不变。状态的改变叫做转移，状态改变的相关概率叫做转移概率。
- 马尔可夫链中的三元素是：状态空间 S 、转移概率矩阵 P 、初始概率分布 π 。



马尔可夫链案例

- 设将天气状态分为晴、阴、雨三种状态，假定某天的天气状态只和上一天的天气状态有关，状态使用1(晴)、2(阴)、3(雨)表示，转移概率矩阵P如下：

今/明	晴	阴	雨
晴	0.75	0.125	0.125
阴	0.5	0.25	0.25
雨	0.25	0.5	0.25



马尔可夫链案例

- 第n+1天天气状态为j的概率为：

$$\pi(X_{n+1} = j) = \sum_{i=1}^K \pi(X_n = i) \cdot P(X_{n+1} = j | X_n = i)$$

$$\Rightarrow \pi^{n+1} = \pi^n \cdot P$$

- 因此，矩阵P即为条件概率转移矩阵。

- ◆ 矩阵P的第i行元素表示，在上一个状态为i的时候的分布概率，即每行元素的和必须为1

马尔可夫链案例

初始概率 $\pi[0.5,0.3,0.2]$

第n天	晴	阴	雨
0	0.5	0.3	0.2
1	0.575	0.2375	0.1875
2	0.5969	0.225	0.1781
3	0.6047	0.2199	0.1754
4	0.6073	0.2183	0.1744
5	0.6082	0.2177	0.1741
6	0.6085	0.2175	0.174
7	0.6086	0.2174	0.1739
8	0.6087	0.2174	0.1739
9	0.6087	0.2174	0.1739
10	0.6087	0.2174	0.1739
11	0.6087	0.2174	0.1739

$$P = \begin{bmatrix} 0.75 & 0.125 & 0.125 \\ 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \end{bmatrix}$$


马尔可夫链案例 初始概率 $\pi[0.1,0.6,0.3]$

$$P = \begin{bmatrix} 0.75 & 0.125 & 0.125 \\ 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \end{bmatrix}$$


第n天	晴	阴	雨
0	0.1	0.6	0.3
1	0.45	0.3125	0.2375
2	0.5531	0.2531	0.1937
3	0.5898	0.2293	0.1809
4	0.6022	0.2215	0.1763
5	0.6065	0.2188	0.1747
6	0.6079	0.2179	0.1742
7	0.6084	0.2176	0.174
8	0.6086	0.2174	0.1739
9	0.6087	0.2174	0.1739
10	0.6087	0.2174	0.1739
11	0.6087	0.2174	0.1739

HMM

- 隐马尔可夫模型(Hidden Markov Model, HMM)是一种统计模型，在语音识别、行为识别、NLP、故障诊断等领域具有高效的性能。
- HMM是关于时序的概率模型，描述一个含有未知参数的马尔可夫链所生成的不可观测的状态随机序列，再由各个状态生成观测随机序列的过程。HMM是一个双重随机过程---具有一定状态的隐马尔可夫链和随机的观测序列。
- HMM随机生成的状态随机序列被称为状态序列；每个状态生成一个观测，由此产生的观测随机序列，被称为观测序列。



HMM



- z_1, z_2, \dots, z_n 是不可观测的状态， x_1, x_2, \dots, x_n 是可观测到的序列
- 在 z_1 、 z_2 不可观测的情况下， x_1 和 z_2 独立吗？ x_1 和 x_2 独立吗？

HMM

- HMM由隐含状态S、可观测状态O、初始状态概率矩阵 π 、隐含状态转移概率矩阵A、可观测值转移矩阵B(又称为混淆矩阵, Confusion Matrix);
- π 和A决定了状态序列, B决定观测序列, 因此HMM可以使用三元符号表示, 称为HMM的三元素:

$$\lambda = (A, B, \pi)$$

HMM参数说明 $\lambda = (A, B, \pi)$

- S是所有可能的状态集合： $S = \{s_1, s_2, \dots, s_n\}$
- O是所有可能的观测集合： $O = \{o_1, o_2, \dots, o_m\}$
- I是长度为T的状态序列，Q是对应的观测序列

$$I = \{i_1, i_2, \dots, i_T\} \quad Q = \{q_1, q_2, \dots, q_T\}$$

HMM参数 $\lambda = (A, B, \pi)$

- A是隐含状态转移概率矩阵:

$$A = [a_{ij}]_{n \times n} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

- 其中 $a_{ij} = p(i_{t+1} = s_j | i_t = s_i)$

◆ a_{ij} 是在时刻t处于状态 s_i 的条件下时刻t+1转移到状态 s_j 的概率。

HMM参数 $\lambda = (A, B, \pi)$

- B是可观测值转移概率矩阵:

$$B = [b_{ij}]_{n \times m} = \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1m} \\ b_{21} & b_{22} & \dots & b_{2m} \\ \dots & \dots & \dots & \dots \\ b_{n1} & b_{n2} & \dots & b_{nm} \end{bmatrix}$$

- 其中 $b_{ij} = p(q_t = o_j | i_t = s_i)$

◆ b_{ij} 是在时刻t处于状态 s_i 的条件下生成观测值 o_j 的概率。

HMM参数 $\lambda = (A, B, \pi)$


- π 是初始状态概率向量:

$$\pi = (\pi_i)_{1*n} = (\pi_1, \pi_2, \dots, \pi_n)$$

- 其中 $\pi_i = p(i_1 = s_i)$

◆ π_i 是在时刻 $t=1$ 处于状态 s_i 的概率。

HMM的两个基本性质



$$p(i_t | i_{t-1}, q_{t-1}, i_{t-2}, q_{t-2}, \dots, i_1, q_1) = p(i_t | i_{t-1})$$

$$p(q_t | i_t, i_{t-1}, q_{t-1}, i_{t-2}, q_{t-2}, \dots, i_1, q_1) = p(q_t | i_t)$$

HMM案例

- 假设有三个盒子，编号为1,2,3；每个盒子都装有黑白两种颜色的小球，球的比例如下：

编号	白球	黑球
1	4	6
2	8	2
3	5	5

- 按照下列规则的方式进行有放回的抽取小球，得到球颜色的观测序列：
 - ◆ 按照 π 的概率选择一个盒子，从盒子中随机抽取一个小球，记录颜色后，放回盒子中；
 - ◆ 按照某种条件概率选择新的盒子，重复该操作；
 - ◆ 最终得到观测序列：“白黑白白黑”

HMM案例

■ 状态集合： $S=\{\text{盒子1}, \text{盒子2}, \text{盒子3}\}$

■ 观测集合： $O=\{\text{白}, \text{黑}\}$

■ 状态序列和观测序列的长度 $T=5$

■ 初始概率分布 π

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

■ 状态转移概率矩阵A

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix}$$

■ 观测概率矩阵B

$$B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

HMM案例思考

- 在给定参数 π 、A、B的时候，得到观测序列为“白黑白白黑”的概率是多少??

HMM的三个问题

■ 概率计算问题：**前向-后向算法**

- ◆ 给定模型 $\lambda=(A,B,\pi)$ 和观测序列 $Q=\{q_1,q_2,\dots,q_T\}$ ，计算模型 λ 下观测到序列 Q 出现的概率 $P(Q|\lambda)$

■ 学习问题：**Baum-Welch算法**(状态未知)

- ◆ 已知观测序列 $Q=\{q_1,q_2,\dots,q_T\}$ ，估计模型 $\lambda=(A,B,\pi)$ 的参数，使得在该模型下观测序列 $P(Q|\lambda)$ 最大。

■ 预测问题：**Viterbi算法**

- ◆ 给定模型 $\lambda=(A,B,\pi)$ 和观测序列 $Q=\{q_1,q_2,\dots,q_T\}$ ，求给定观测序列条件概率 $P(I|Q, \lambda)$ 最大的状态序列 I

概率计算问题

- 直接算法
 - ◆ 暴力算法
- 前向算法
- 后向算法

直接计算法

- 按照概率公式，列举所有可能的长度为T的状态序列 $I = \{i_1, i_2, \dots, i_T\}$ ，求各个状态序列I与观测序列 $Q = \{q_1, q_2, \dots, q_T\}$ 的联合概率 $P(Q, I; \lambda)$ ，然后对所有可能的状态序列求和，从而得到最终的概率 $P(Q; \lambda)$

$$I = \{i_1, i_2, \dots, i_T\} \quad p(I; \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T}$$

$$Q = \{q_1, q_2, \dots, q_T\} \quad p(Q|I; \lambda) = b_{i_1 q_1} b_{i_2 q_2} \dots b_{i_T q_T}$$


$$P(Q, I; \lambda) = p(Q|I; \lambda) p(I; \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T} b_{i_1 q_1} b_{i_2 q_2} \dots b_{i_T q_T}$$

$$p(Q; \lambda) = \sum_I p(Q, I; \lambda) = \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T} b_{i_1 q_1} b_{i_2 q_2} \dots b_{i_T q_T}$$

前向概率-后向概率

$$\alpha_t(i) = P(y_1, y_2, \dots, y_t, q_t = i | \lambda)$$

$$\beta_t(i) = P(y_{t+1}, y_{t+2}, \dots, y_T | q_t = i, \lambda)$$



前向算法

- 定义：给定 λ ，定义到时刻 t 部分观测序列为 q_1, q_2, \dots, q_t 且状态为 s_i 的概率为**前向概率**。记做：

$$\alpha_t(i) = p(q_1, q_2, \dots, q_t, i_t = s_i; \lambda)$$

前向算法 $\alpha_t(i) = p(q_1, q_2, \dots, q_t, i_t = s_i; \lambda)$

■ 初值： $\alpha_1(i) = p(q_1, i_1 = s_i; \lambda) = \pi_i b_{iq_1}$

■ 递推：对于 $t=1, 2, \dots, T-1$

$$\alpha_{t+1}(i) = \left(\sum_{j=1}^n \alpha_t(j) a_{ji} \right) b_{iq_{t+1}}$$

■ 最终：

$$P(Q; \lambda) = \sum_{i=1}^n \alpha_T(i)$$

HMM案例-前向算法

- 在给定参数 π 、 A 、 B 的时候，得到观测序列为“白黑白白黑”的概率是多少??

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

HMM案例-前向算法

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix} \quad A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

$$\alpha_1(1) = \pi_1 b_{1q_1} = 0.08$$

$$\alpha_1(2) = \pi_2 b_{2q_1} = 0.4$$

$$\alpha_1(3) = \pi_3 b_{3q_1} = 0.15$$

HMM案例-前向算法

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix} \quad A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix} \quad B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

$$\alpha_1(1) = \pi_1 b_{1q_1} = 0.08$$

$$\alpha_1(2) = \pi_2 b_{2q_1} = 0.4$$

$$\alpha_1(3) = \pi_3 b_{3q_1} = 0.15$$

$$\alpha_2(1) = \left(\sum_{j=1}^3 \alpha_1(j) a_{j1} \right) b_{1q_2}$$

$$= (0.08 * 0.5 + 0.4 * 0.2 + 0.15 * 0.2) * 0.6$$

$$= 0.09$$

$$\alpha_2(2) = 0.0374$$

$$\alpha_2(3) = 0.1465$$

$$\alpha_3(1) = 0.032712$$

$$\alpha_4(1) = 0.01702872$$

$$\alpha_5(1) = 0.0142036956$$

$$\alpha_3(2) = 0.0933384$$

$$\alpha_4(2) = 0.04048728$$

$$\alpha_5(2) = 0.0065122938$$

$$\alpha_3(3) = 0.037695$$

$$\alpha_4(3) = 0.03530505$$

$$\alpha_5(3) = 0.0182933775$$

HMM案例-前向算法

$$\alpha_5(1) = 0.0142036956$$

$$\alpha_5(2) = 0.0065122938$$

$$\alpha_5(3) = 0.0182933775$$

$$p(Q; \lambda) = \sum_{i=1}^3 \alpha_5(i)$$

$$= 0.0142036956 + 0.0065122938 + 0.0182933775$$

$$= 0.0390093669$$

后向算法

- 定义：给定 λ ，定义到时刻 t 状态为 s_i 的前提下，从 $t+1$ 到 T 部分观测序列为 $q_{t+1}, q_{t+2}, \dots, q_T$ 的概率为**后向概率**。记做：

$$\beta_t(i) = p(q_{t+1}, q_{t+2}, \dots, q_T | i_t = s_i; \lambda)$$

后向算法 $\beta_t(i) = p(q_{t+1}, q_{t+2}, \dots, q_T | i_t = s_i; \lambda)$

■ 初值： $\beta_T(i) = 1$

■ 递推：对于 $t = T-1, T-2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^n (a_{ij} b_{jq_{t+1}} \beta_{t+1}(j))$$

■ 最终：

$$P(Q; \lambda) = \sum_{i=1}^n \pi_i b_{iq_1} \beta_1(i)$$

单个状态的概率

- 求给定模型 λ 和观测序列 Q 的情况下，在时刻 t 处于状态 s_i 的概率，记做：

$$\gamma_t(i) = p(i_t = s_i | Q; \lambda)$$

- 单个状态概率的意义主要是用于判断在每个时刻最可能存在的状态，从而可以得到一个状态序列作为最终的预测结果。

单个状态的概率

$$p(i_t = s_i, Q; \lambda) = \alpha_t(i) \beta_t(i)$$

$$\gamma_t(i) = p(i_t = s_i | Q; \lambda) = \frac{p(i_t = s_i, Q; \lambda)}{p(Q; \lambda)}$$

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{P(Q; \lambda)} = \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^n \alpha_t(j) \beta_t(j)}$$

两个状态的联合概率

- 求给定模型 λ 和观测序列 Q 的情况下，在时刻 t 处于状态 s_i 并时刻 $t+1$ 处于状态 s_{j+1} 概率，记做：

$$\xi_t(i, j) = p(i_t = s_i, i_{t+1} = s_j | Q; \lambda)$$

两个状态的联合概率

$$\begin{aligned}
 \xi_t(i, j) &= p(i_t = s_i, i_{t+1} = s_j | Q; \lambda) \\
 &= \frac{p(i_t = s_i, i_{t+1} = s_j, Q; \lambda)}{p(Q; \lambda)} \\
 &= \frac{p(i_t = s_i, i_{t+1} = s_j, Q; \lambda)}{\sum_{i=1}^n \sum_{j=1}^n p(i_t = s_i, i_{t+1} = s_j, Q; \lambda)}
 \end{aligned}$$

$$p(i_t = s_i, i_{t+1} = s_j, Q; \lambda) = \alpha_t(i) a_{ij} b_{jq_{t+1}} \beta_{t+1}(j)$$

学习问题

- 若训练数据包含观测序列和状态序列，则HMM的学习问题非常简单，是监督学习算法。
- 若训练数据只包含观测序列，则HMM的学习问题需要使用EM算法求解，是非监督学习算法。

学习问题_监督学习

- 直接利用大数定理的结论 “频率的极限是概率” ，直接给出HMM的参数估计；

$$\hat{\pi}_i = \frac{|s_i|}{\sum_{i=1}^n |s_i|}$$

$$a_{ij} = \frac{|s_{ij}|}{\sum_{j=1}^n |s_{ij}|}$$

$$\hat{b}_{ij} = \frac{|q_{ij}|}{\sum_{j=1}^m |q_{ij}|}$$

学习问题_非监督学习

- 若训练数据中只有观测序列，则HMM的学习问题需要使用EM算法，属于非监督算法；此时一般使用Baum-Welch算法。
- 所有的观测数据为 $Q=\{q_1, q_2, \dots, q_T\}$ ，所有的隐状态为 $I=\{i_1, i_2, \dots, i_T\}$ ，则完整的数据为 (O, I) ，完整数据的对数似然函数为 $\ln(p(Q, I; \lambda))$ ；然后直接使用EM算法的方式进行参数估计。

Baum-Welch算法

$$p(O, I; \lambda) = \pi_{i_1} b_{i_1 q_1} a_{i_1 i_2} b_{i_2 q_2} \dots a_{i_{T-1} i_T} b_{i_T q_T}$$

$$L(\lambda, \bar{\lambda}) = \sum_I \ln(p(Q, I; \lambda)) p(I|Q; \bar{\lambda})$$

$$= \sum_I \ln(p(Q, I; \lambda)) \frac{p(I, Q; \bar{\lambda})}{p(Q; \bar{\lambda})}$$

$$\propto \sum_I \ln(p(Q, I; \lambda)) p(I, Q; \bar{\lambda})$$

$$L(\lambda, \bar{\lambda}) = \sum_I \ln(\pi_{i_1}) p(I, Q; \bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} \right) p(I, Q; \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \ln b_{i_t q_t} \right) p(I, Q; \bar{\lambda})$$

Baum-Welch算法

- 极大化L函数，分别可以求得 π 、 a 、 b 的值。

$$\pi_i = \gamma_1(i) \quad a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad b_{ij} = \frac{\sum_{t=1, q_t=o_j}^T \gamma_t(i)}{\sum_{t=1}^T \gamma_t(i)}$$

预测问题

- 近似算法
- Viterbi算法

近似算法

- 直接在每个时刻t时候最优可能的状态作为最终的预测状态，使用下列公式计算概率值：

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(Q; \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^n \alpha_t(j)\beta_t(j)}$$

Viterbi算法

- Viterbi算法实际是用动态规划的思路求解HMM预测问题，求出概率最大的“路径”，每条“路径”对应一个状态序列。

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} p(i_t = i, i_1, i_2, \dots, i_{t-1}, q_t, q_{t-1}, \dots, q_1; \lambda)$$

$$\delta_1(i) = \pi_i b_{iq_1} \quad \delta_{t+1}(i) = \max_{1 \leq j \leq n} (\delta_t(j) a_{ji}) b_{iq_{t+1}}$$

$$P^* = \max_{1 \leq i \leq n} \delta_T(i)$$

HMM案例-Viterbi

- 在给定参数 π 、 A 、 B 的时候，得到观测序列为“白黑白白黑”，求出最优的隐藏状态序列。

$$\pi = \begin{pmatrix} 0.2 \\ 0.5 \\ 0.3 \end{pmatrix}$$

$$A = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.2 & 0.2 & 0.6 \\ 0.2 & 0.5 & 0.3 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.4 & 0.6 \\ 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

HMM案例-Viterbi

$$\delta_1(i) = \pi_i b_{iq_1} = \pi_i b_{i白}$$

$$\begin{aligned}\delta_1(1) &= 0.08 \\ \delta_1(2) &= 0.4 \\ \delta_1(3) &= 0.15\end{aligned}$$

$$\delta_2(i) = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{iq_2} = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{i黑}$$

$$\delta_2(1) = \max\{0.08 * 0.5, 0.4 * 0.2, 0.15 * 0.2\} * 0.6 = 0.048$$

$$\delta_2(2) = \max\{0.08 * 0.4, 0.4 * 0.2, 0.15 * 0.5\} * 0.2 = 0.016$$

$$\delta_2(3) = \max\{0.08 * 0.1, 0.4 * 0.6, 0.15 * 0.3\} * 0.5 = 0.12$$

HMM案例-Viterbi

$\delta_1(1) = 0.08$	$\delta_2(1) = 0.048$
$\delta_1(2) = 0.4$	$\delta_2(2) = 0.016$
$\delta_1(3) = 0.15$	$\delta_2(3) = 0.12$

$\delta_3(1) = 0.0096$	$\delta_4(1) = 0.00384$	$\delta_5(1) = 0.001728$
$\delta_3(2) = 0.048$	$\delta_4(2) = 0.00768$	$\delta_5(2) = 0.00144$
$\delta_3(3) = 0.018$	$\delta_4(3) = 0.0144$	$\delta_5(3) = 0.002304$

■ 最终盒子序列为: (2, 3, 2, 2, 3)

HMM应用

■ 安装pip install hmmlearn


```
C:\Users\ibf>pip install hmmlearn
Collecting hmmlearn
  Downloading hmmlearn-0.2.0.tar.gz (107kB)
    9% |██████████| 10kB 39kB/s 18% |██████████| 20kB 79k 28% |██████████|
    30kB 37% |██████████| 4 47% |██████████|
    66% |██████████| 75% |██████████|
    94% |██████████| 100% |██████████|
    112kB 245kB/s
Building wheels for collected packages: hmmlearn
  Running setup.py bdist_wheel for hmmlearn ... done
  Stored in directory: C:\Users\ibf\AppData\Local\pip\Cache\wheels\de\6c\25\c5fc03ff58b509d7b9769a0d5e2f69fc3fe89feebd70b89b86
Successfully built hmmlearn
Installing collected packages: hmmlearn
Successfully installed hmmlearn-0.2.0
```

■ HMM的常见应用主要用于进行特征提取的场景中或者数据标注的场景中；

作业

- 假定天气状态的条件转移矩阵如下，观测到的数据即状态信息，假定今天的天气为晴天，那么接下来的五天的天气最有可能的天气序列是什么??(使用Viterbi算法求解)

今/明	晴	阴	雨
晴	0.75	0.125	0.125
阴	0.5	0.25	0.25
雨	0.25	0.5	0.25





THANK YOU

上海育创网络科技有限公司